

1. What is the use case / task that the authors are tackling? (20%)

Paper tersebut membahas mengenai deteksi tumor otak menggunakan magnetic resonance imaging (MRI) menggunakan deep learning, khususnya model YOLOv7. Tujuan dari paper ini dibuat adalah untuk:

- Mendeteksi keberadaan tumor (glioma, meningioma, dan pituitary tumor)
- Menentukan lokasi tumor secara akurat pada gambar MRI

Paper ini tidak hanya mengklasifikasi biner tetapi juga memberi bounding box dan klasifikasi jenis tumor (glioma, meningioma, pituitary).

Dataset yang dipakai adalah dataset dari Kaggle yang berisikan 10.288 gambar dan terbagi menjadi 2.548, pituitary 2.658, meningioma 2.582, dan no tumor 2.500, dengan split 80% train = 8.232, 20% test = 2.056. setelah augmentasi. Jumlah citra training membesar menjadi total 51.448 gambar untuk pelatihan.

Target aplikasinya adalah membantu radiolog untuk mendukung keputusan klinis dengan deteksi cepat dan lokasi tumor yang presisi di gambar MRI.

2. Why did the authors propose their method? (20%)

Penulis menggunakan metode:

- YOLOv7, karena model ini sudah terbukti efektif dalam mendeteksi objek umum, sehingga penulis menerapkan dan memodifikasinya untuk domain medis.
- CBAM (convolutional Block Attention Module) untuk membuat model fokus pada area penting di otak
- SPPF+ (spatial Pyramid Pooling Fast+) dan BiFPN (Bi-directional Feature Pyramid Network) untuk membantu model mengenali tumor dari berbagai ukuran (besar maupun kecil).
- Transfer learning dan augmentasi data digunakan untuk meningkatkan performa model, terutama karena data medis umumnya terbatas.
- Dibandingkan segmentation pixel-wise yang berat, pendekatan berbasis bounding-box (deteksi objek) lebih ringan secara komputasi dan lebih portable untuk aplikasi klinis cepat.

Motivasi teknis dan klinis model ini dibuat:

Keterbatasan proses manual -> interpretasi MRI oleh manusia memakan waktu, variatif antar-pengamat, rentan kesalahan, sehingga sistem otomatis dapat mengurangi beban dan meningkatkan konsistensi diagnosis.

3. What are its advantages and disadvantages? (10%)

Keuntungan:

- Akurasi tinggi secara kuantitatif  
Model yang diusulkan (YOLOv7 + CBAM + SPPF+ + BiFPN + decoupled head) mencapai 99.5% accuracy (PR 99.5%, RE 99.3%, F1 99.4% dalam eksperimen Mereka). Paper menunjukkan bahwa konfigurasi penuh memberikan performa terbaik dalam ablation study
- Deteksi lokasi + kelas sekaligus  
Memberi bounding box dan klasifikasi jenis tumor -> lebih berguna klinis dibanding klasifikasi
- Perbaikan sensitivitas pada objek kecil  
Integrasi SPPF+ & BiFPN + penggabungan peta fitur multi-skala membantu model mengenali tumor kecil yang sering terlewat..

- Penggunaan transfer learning & augmentasi  
Memanfaatkan bobot pre-training (COCO) + augmentasi yang meningkatkan generalisasi walaupun dataset asli relative terbatas.
- Ablation study mendukung arsitektur:  
Penulis menguji berbagai kombinasi modul (CBAM vs SE/ECA; SPPF+/biFPN/DP) dan menunjukkan kontribusi positif masing-masing modul terhadap metrik.
- Lebih efisien daripada beberapa metode segmentasi penuh  
Resource & storage lebih kecil sehingga lebih mudah di-delay.

#### Kelemahan:

- Validasi klinis terbatas/ generalisasi ke data nyata  
Model diuji pada dataset public, paper mengakui belum divalidasi luas pada data klinis multi-center, dalam paper diakui belum divalidasi luas pada data klinis multi-center, perbedaan scanner, protocol MRI, dan artefak klinis dapat menurunkan performa.
- Bounding box vs segmentasi  
Bbounding box tidak selalu menandai batas tumor secara presisi, untuk aplikasi seperti perencanaan operasi atau radioterapi, segmentasi pixel-wise sering diperlukan.
- Deteksi tumor sangat kecil masih menantang  
Meskipun peningkatan, penulis mengakui deteksi *very small lesions* butuh riset lebih lanjut dan contoh data kecil yang representative.
- Potensi overfitting/ ketergantungan pada preprocessing  
Meskipun augmentasi digunakan, model masih bisa "terikat" pada karakteristik dataset, preprocessing agresif atau preprocessing agresif atau perbedaan distribusi data bisa menurunkan akurasi.
- Biaya dan anotasi yang tinggi  
Membuat dataset berlabel bounding boxes untuk YOLO memerlukan anotasi klinis yang mahal dan memakan waktu
- Kebutuhan compute untuk training  
Pelatihan fine-tuned YOLOv7 dengan modul tambahan masih memerlukan GPU (Mereka melatih di Nvidia 1080Ti). Ini relevan untuk replikasi penelitian
- Perbandingan antar studi sulit  
Penulis menekankan bahwa perbandingan landing antar paper harus hati-hati perbedaan preprocess, pembagian data, dan metrics